

Tarea 4.

La fecha de entrega es el **25 de octubre de 2021**.

Lecturas

- Introduction to simulation using R Capítulo 13
- Marc C. Bove, et. al Effect of El Niño on U.S. Landfalling Hurricanes, Revisited
- Dagpunar, Capítulo 7, Secciones 7.1-7.3

Problemas

1. Consideren este problema de Manufactura. La compañía A tiene una configuración de dos máquinas, cada una de las cuales produce un componente por hora. Cada componente puede ser probado de manera instantánea para identificar si es defectuoso o no defectuoso. Sea a_i la probabilidad de que un componente producido por la máquina i sea no defectuoso, $i = 1, 2$. Los componentes defectuosos son desechados y los no defectuosos producidos por cada máquina se almacenan en dos armarios separados. Cuando un componente está presente en cada armario, los dos se ensamblan instantáneamente y se envían. Cada armario puede mantener a lo más dos componentes. Cuando un armario está lleno, la máquina correspondiente se apaga. Se prende de nuevo cuando el armario tiene espacio para al menos un componente.
 - Modelar este proceso como una cadena de Markov.
 - Suponiendo que $a_1 = 0.3$ y $a_2 = 0.5$, generar 500 pasos de la cadena. Digan qué condiciones iniciales usaron para esa trayectoria. ¿Qué proporción del tiempo pasa cada una de las máquinas apagadas?

Solución.

- Este problema suena un poco complicado en el setup porque hay eventos anidados, por un lado es el producto que se genera de cada máquina, y por el otro,

se tiene el almacenamiento. En realidad lo que define el proceso son los estados finales, es decir, el estado de los almacenes.

Definimos A_n el número de productos en el almacén de la máquina A y B_n el número de componentes de la máquina B , ambos al final de la n -ésima hora. Tenemos que $A_n, B_n \in \{0, 1, 2\}$. Notemos que los almacenes no pueden estar no vacíos simultáneamente, porque el ensamble es simultáneo. Así que $A_n > 0$ implica que $B_n = 0$ y simultáneamente. Sea X_n el estado del almacén en la hora n . Tenemos que X_n toma valores en $\{(0, 0), (0, 1), (0, 2), (1, 0), (2, 0)\}$. Otra opción es definir X_n como la diferencia $A_n - B_n$, con espacio de estados $\{-2, -1, 0, 1, 2\}$. Cualquiera de las dos opciones funciona bien. Usando la última versión, tenemos que:

$$P = \begin{pmatrix} 1-a_1 & a_1 a_2 + (1-a_1)(1-a_2) & a_1(1-a_2) & 0 & 0 \\ (1-a_1)a_2 & (1-a_1)a_2 & a_1 a_2 + (1-a_1)(1-a_2) & 0 & 0 \\ 0 & 0 & (1-a_1)a_2 & a_1(1-a_2) & 0 \\ 0 & 0 & 0 & a_1 a_2 + (1-a_1)(1-a_2) & 0 \\ 0 & 0 & 0 & a_2 & 1-a_2 \end{pmatrix}$$

- Para los valores dados, generamos X , considerando $X_0 = 0$. Adicionalmente, los casos en donde las máquinas están apagadas son las rachas de -2 o 2.

```
a1 <- 0.3
a2 <- 0.5
a <- (1-a1)*a2
b <- a1*a2 + (1-a1)*(1-a2)
c <- a1*(1-a2)
P <- matrix(c(1-a2,a,0,0,0,
a1,b,a,0,0,
0,c,b,a,0,
0,0,c,b,a2,
0,0,0,c,1-a2),nrow= 5)

X <- 0 # estado inicial
S <- c(-2,-1,0,1,2)
for(i in 1:500){
  ind <- which(X[i] == S) # fija el indice
  X[i+1] <- sample(S,size = 1,prob = P[ind,])
}
X

[1] 0 0 -1 -2 -2 -1 -1 0 1 2 2 1 1 1 1 1 0 0 0 0 0 0 -1 -1 0
[26] 0 -1 -2 -1 -2 -2 -2 -2 -1 -1 -2 -1 -1 -1 -2 -2 -2 -1 -2 -1 0 -1 -1 -2
[51] -1 -1 -2 -1 -1 -1 -2 -1 -1 -1 0 -1 -2 -2 -2 -2 -1 -2 -2 -1 -2 -2 -2 -1
[76] -1 -1 -1 -2 -2 -2 -2 -1 -1 -2 -2 -2 -1 -1 -2 -1 -2 -2 -2 -1 -1 0 1 1 2
[101] 2 1 2 1 1 1 1 1 1 0 -1 -2 -1 0 -1 -1 -1 -1 -2 -1 -1 -1 -1 -2 -2
[126] -1 -2 -2 -2 -2 -1 -1 -2 -1 -1 -2 -2 -2 -1 -2 -1 -2 -2 -2 -2 -2 -2 -2 -2
[151] -2 -2 -2 -2 -2 -1 0 1 1 1 1 1 1 1 0 0 0 -1 0 -1 -2 -2 -2 -2 -1
[176] -1 -1 -2 -1 -1 -1 -2 -2 -1 -1 -2 -1 -2 -2 -2 -1 -2 -1 -2 -2 -1 -1 0 1
[201] 1 0 0 0 -1 -2 -2 -2 -1 -1 -1 -1 -2 -2 -2 -2 -1 -1 0 1 1 1 2 1
[226] 1 1 0 -1 -2 -2 -2 -1 0 0 1 1 2 2 1 1 2 2 1 1 0 1 0 -1 -1
[251] -1 0 -1 -1 -2 -1 -1 -1 -1 -2 -2 -1 -1 -1 -1 0 -1 0 0 -1 -1 -1 -1 -1
[276] -2 -2 -2 -2 -2 -2 -2 -2 -1 -1 -2 -1 -1 0 0 0 1 0 0 -1 -1 -1 -1 -2 -2
[301] -2 -2 -1 -1 -1 -1 -1 -2 -1 -1 -1 -2 -2 -2 -2 -2 -2 -2 -1 0 -1 -2 -2 -2
[326] -1 -1 -2 -2 -2 -2 -2 -2 -2 -1 -2 -2 -2 -2 -1 -2 -1 -1 0 -1 -2 -2 -2 -2
[351] -2 -2 -2 -2 -1 0 0 0 -1 -1 0 0 1 1 2 1 0 -1 -2 -2 -1 0 1 0 0
[376] 0 0 1 1 2 1 1 2 1 2 2 1 0 1 1 1 1 0 -1 -2 -2 -2 -2 -2 -2
[401] -2 -2 -2 -2 -2 -1 -2 -1 -1 -1 -1 0 -1 -2 -1 0 -1 -1 -2 -1 -2 -1 -1 -1
[426] -1 -2 -1 -2 -2 -2 -2 -2 -2 -1 -1 -1 -1 -1 0 1 2 2 2 1 0 -1 -2 -1
[451] -2 -2 -1 -1 0 0 0 0 1 0 0 0 -1 -2 -2 -1 -1 -1 -2 -1 -1 -1 -2 -1 -2
[476] -2 -2 -2 -2 -2 -1 -1 0 -1 -1 -1 -2 -1 0 0 0 -1 0 0 1 1 0 -1 -1 -1
[501] -2

a <- table(X)/length(X) # proporciones de valores observados.
sum(a[c(1,5)]) # suma los casos de -2 o 2

[1] 0.3892216
```

□

2. Para un proceso Poisson no homogéneo con función de intensidad dada por

$$\lambda(t) = \begin{cases} 5, t \in (1, 2], (3, 4], \dots \\ 3, t \in (0, 1], (2, 3], \dots \end{cases}$$

- Grafiquen una ejemplo del proceso considerando el intervalo de tiempo [0,100].
- Grafiquen el proceso hasta obtener 100 eventos
- Estimen la probabilidad de que el número de eventos observados en el periodo de tiempo (1.25,3] es mayor que 2.

Solución.


Para el primer problema, tenemos que definir la función pulso. Debido a que en el proceso de aceptación-rechazo se pierden algunas observaciones, el numero de observaciones necesarios para llegar al tiempo 100 se obtiene por ensayo y error, o bien, cambiar la programación y primero generar todas las exponenciales hasta que se acumule el número que necesitamos. Yo hice la otra programación.

```
lambdat2 <- function(t){
  x <- paste("", "{", 0, "<= t & t < ", 1, "}", sep="")
  for(i in seq(2,100,2)){x <- paste(x, paste("{", i, "<= t & t < ", i+1, "}", sep=""), sep="|")}
  return(ifelse(eval(parse(text=x)), 3, 5))
}

ppnh <- function(lambdat, n, pic=T){
  lambda <- 5 # mayoriza la función lambdat
  TT <- rexp(n, lambda) # genera variables exponenciales para los tiempos.
  s <- cumsum(TT) # acumula los tiempos en el vector s
  u <- runif(n) # obten n uniformes
  ss <- s[u <= lambdat(s)/lambda] # obten los tiempos que cumplen la condición de aceptación
  Ns <- 1:length(ss) # Conteo
  if(pic==T){
    plot(ss, Ns, type = "s", xlab = "epocas", ylab = "N(t)",
         main = "Simulación de un proceso Poisson no homogeneo",
         sub = expression(lambda(t) == paste(lambdat2, "(t)"))
    )
    return(list(epocas = ss, cuenta= Ns))
  }
}

ppnh(lambdat = lambdat2, n = 510)
```

Simulacion de un proceso Poisson no homogeneo




\$epocas					
[1]	0.7273535	1.1338008	1.3552472	1.5469604	1.7917484
[7]	1.9387997	1.9673649	1.9741642	2.1908091	2.6207073
[13]	2.6330046	3.2525420	3.3158688	3.4334635	3.5402580
[19]	3.8384862	4.6394271	5.0858394	5.1887024	5.3124164
[25]	5.5394629	5.5803193	5.7337350	5.7607577	5.8031695
[31]	6.2693518	6.8147633	6.9900900	7.2493361	7.3549049
[37]	7.5936208	7.8296747	7.9571245	8.4497609	8.6361922
[43]	9.2392034	9.4091465	9.7495532	9.8434041	10.1063639
[49]	11.3202017	11.3536483	11.8205068	11.9155830	11.9416496
[55]	12.7684581	13.0431094	13.0629136	13.4462693	13.4843982
[61]	14.0450121	14.0925341	14.2463440	14.3243700	14.4181247
[67]	15.0975058	15.3700316	15.6381201	15.6463827	15.8204983
[73]	16.9260204	17.2945940	17.5281280	17.7755107	17.7847989
[79]	18.6870383	19.0211184	19.0440896	19.5691781	19.9205975
[85]	20.4870939	20.7934705	20.9552478	21.0773011	21.6277807
[91]	21.8239780	21.8730442	21.8919720	21.9418455	22.2840036
[97]	23.4752403	24.5115071	25.3989402	25.4491098	25.8892038
[103]	26.3219599	26.3281609	26.3839011	27.1900769	27.4378156
[109]	27.8207874	28.6684819	28.8317401	28.9342260	28.9846293
[115]	29.3083967	29.5323066	29.6447735	29.6481687	29.8176106
[121]	30.7011055	30.7454994	30.7937562	30.8417129	31.2248349
[127]	31.3440529	32.6135376	32.7776891	33.0916930	33.0989957
[133]	33.6766503	34.0180673	34.0523241	34.2876682	34.6648736
[139]	35.5122092	35.6913163	36.1153665	36.6078178	36.6378108
[145]	36.9350670	37.3768803	37.6833465	37.7237535	37.8066341
[151]	38.4971614	38.8591864	39.7788447	40.4823632	40.5911093
[157]	41.1542778	41.5206517	41.6484244	41.7762769	42.2162619
[163]	43.1771297	43.4110118	43.5747921	43.9313959	43.9747378
[169]	45.0155948	45.1113615	45.8644247	45.9273589	46.0672420
[175]	47.5619032	47.8119583	47.8690824	48.5353052	48.7486323
[181]	49.2051229	49.3892360	49.4165069	49.4850327	49.8756650
[187]	50.4651693	51.2817923	51.3981107	51.9067635	52.1907779
[193]	52.7282716	52.7688026	53.0879191	53.0960012	53.1460518
[199]	53.5632005	53.9452399	54.4333029	54.4613283	55.0807249
[205]	56.0565203	56.2869749	56.9731566	57.9193479	58.1728275
[211]	59.1627575	59.5924753	59.6443139	59.7232180	60.5595843
[217]	60.7034270	61.0069995	61.0571172	61.1490030	61.3399563
[223]	61.8643597	62.0081260	63.0758238	63.0981780	63.5186951
[229]	63.7202409	64.3526218	64.4073313	64.6519161	65.2926738
[235]	65.8392633	67.0452981	67.2382194	67.4318599	67.7997264
[241]	68.0556411	68.2512601	68.4094513	68.4407055	68.7331961

[247]	69.1396618	69.7168906	69.8341127	69.8521323	70.1886434	70.2920934
[253]	71.1638953	71.5137203	71.7535805	71.8584489	72.1345316	72.2095194
[259]	72.3985560	72.7671913	73.2779864	73.3857405	73.4382792	73.7458136
[265]	75.0038445	75.2236345	75.3476847	75.6878215	75.7766490	75.9596430
[271]	76.2055628	76.2512934	76.3192955	76.3880338	76.7548409	77.4162306
[277]	78.1917689	78.3991957	79.6563693	79.9158596	79.9925320	80.3648888
[283]	80.9842333	81.4345778	81.4633398	82.3256598	83.1909296	83.2622338
[289]	83.2850392	83.5277234	83.5341853	83.6983583	83.8389134	83.9054786
[295]	83.9354277	83.9692231	83.9805892	84.4445654	84.6743640	85.3136458
[301]	85.4501956	85.4863637	85.9143311	85.9574491	85.9620968	86.1845758
[307]	86.2052994	87.3290688	87.3680089	87.6043988	87.6402261	87.7089351
[313]	87.8591309	88.1779908	88.5622743	89.1796012	89.3270288	89.4958634
[319]	89.5286618	89.6696823	89.8249070	90.1659207	90.3146763	90.4246748
[325]	90.4910635	90.7660317	91.2894780	91.3162132	91.4249657	91.4424916
[331]	91.4936230	92.4454103	92.7130238	93.6381506	93.9067281	93.9515450
[337]	95.0595397	95.2357893	95.5413642	95.5849048	95.6059042	95.6106720
[343]	95.8002589	96.2378695	96.7728502	96.9177850	97.0326046	97.1693794
[349]	97.2151813	97.7616178	97.8971839	98.5690271	99.1534576	99.1873865
[355]	99.4614831	99.4620068	99.5011058	99.5074935	99.6119207	100.7333294
[361]	101.1189023	101.4443589	101.4547555	101.5265310	101.5539204	101.8455666
[367]	101.8758377	101.9811766	102.8835619	103.3866524	103.4013592	103.6745246
[373]	104.1571065	104.2654400	104.3244028	104.7799636	105.0812331	105.2024795
[379]	105.2098205	105.2156497	105.5248935	105.5364964	105.6430823	106.0577667
[385]	106.2766484	106.3084718	106.3166256	106.6129007	107.3500631	107.5614022
[391]	107.5930692	107.8483937	108.1501134	108.3644955	108.4473698	108.6051796
[397]	108.7912095	108.8266174	109.5585691	109.8048012	109.8568226	110.3798668
[403]	110.6225358	111.0668179	111.3753811	111.4955393	111.7806925	111.8323500
[409]	112.0295372	112.2075713	112.4143631	112.4174161	112.7236258	112.7796756
[415]	112.9012131	113.0033867	113.2675867	113.3736240	113.4364990	
\$cuenta						
[1]	1	2	3	4	5	6
[19]	19	20	21	22	23	24
[37]	37	38	39	40	41	42
[55]	55	56	57	58	59	60
[73]	73	74	75	76	77	78
[91]	91	92	93	94	95	96
[109]	109	110	111	112	113	114
[127]	127	128	129	130	131	132
[145]	145	146	147	148	149	150
[163]	163	164	165	166	167	168
[181]	181	182	183	184	185	186
[199]	199	200	201	202	203	204
[217]	217	218	219	220	221	222
[235]	235	236	237	238	239	240
[253]	253	254	255	256	257	258
[271]	271	272	273	274	275	276
[289]	289	290	291	292	293	294
[307]	307	308	309	310	311	312
[325]	325	326	327	328	329	330
[343]	343	344	345	346	347	348
[361]	361	362	363	364	365	366
[379]	379	380	381	382	383	384
[397]	397	398	399	400	401	402
[415]	415	416	417	418	419	

Para obtener 100 eventos es similar, con un tamaño de muestra mucho menor:

`ppnh(lambdat2,140)`

Simulacion de un proceso Poisson no homogeneo



```

$epocas
[1] 0.04039113 0.24935863 0.51599309 0.55848366 0.65933261 0.88046690
[7] 1.15154011 1.20753218 1.31547205 1.53444666 1.69366642 1.84370409
[13] 1.89500143 2.03437802 2.26081417 3.20845370 3.22012695 3.45423840
[19] 3.59726034 3.93118377 3.97844706 4.45047340 5.31090233 5.81735468
[25] 5.85828583 5.88702871 6.29981204 7.31614669 8.28936309 8.38249804
[31] 9.19739366 9.63954746 9.65288273 10.16520545 10.60398328 10.75092080
[37] 11.04279787 11.34200183 11.60457762 11.61883600 11.66966291 11.84250622
[43] 11.94570465 12.07708084 12.90849278 13.61128674 13.63221226 14.38410399
[49] 14.62152599 15.30570955 15.43152207 15.52518385 15.62638568 15.72245934
[55] 15.86545641 17.10338734 17.27165516 17.29981642 17.38725535 17.63570106
[61] 17.74785355 17.75816091 17.94986639 17.98100713 17.99754043 18.18625454
[67] 18.20390612 18.23235409 18.55404022 18.62207310 19.15168047 19.64607340
[73] 19.76414017 19.80664220 20.38101868 20.44866766 21.12340188 21.16891551
[79] 21.25035737 21.26964963 21.35613678 21.38409462 21.46292756 21.49768124
[85] 21.66018703 21.72651005 22.16111979 22.19293020 22.86818213 23.02312898
[91] 23.16984549 23.21647198 23.34774400 23.36585282 23.59986403 24.16125895
[97] 24.66976494 24.99224042 25.12875085 25.26055104 25.29161946 25.41235056
[103] 25.67167890 25.85011150 26.64663804 26.68012655 26.75038610 26.75423746
[109] 27.82954415 27.88771601 27.94400168 28.31294276 28.61195933 28.62444473
[115] 28.72345757 28.77479452 29.27816136 29.40847380 29.54418031 29.58673558
[121] 29.86083569 29.93309720

$cuanta
[1] 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18
[19] 19 20 21 22 23 24 25 26 27 28 29 30 31 32 33 34 35 36
[37] 37 38 39 40 41 42 43 44 45 46 47 48 49 50 51 52 53 54
[55] 55 56 57 58 59 60 61 62 63 64 65 66 67 68 69 70 71 72
[73] 73 74 75 76 77 78 79 80 81 82 83 84 85 86 87 88 89 90
[91] 91 92 93 94 95 96 97 98 99 100 101 102 103 104 105 106 107 108
[109] 109 110 111 112 113 114 115 116 117 118 119 120 121 122

```

Por último, para estimar la probabilidad en el intervalo dado, lo que podemos hacer es obtener N simulaciones, y calcular la proporción de esas simulaciones que dan un valor de conteo mayor a 2 en ese intervalo.

```

fr <- NULL
N <- 10000
for(i in 1:N){
  x <- pphn(lambdat2,10,pic=F);
  fr <- c(fr,ifelse(1.25 < x$epocas[x$cuanta==2] & x$epocas[x$cuanta==2] < 3,1,0))
}

sum(fr)/N

[1] 0.0781

```

□

3. Simular un proceso Poisson no homogéneo con función de intensidad dada por $\lambda(t) = |\sin(t)|$.

Solución.

```


lambdat <- function(t){abs(sin(t))}

ppnh<- function(lambdat,n){
  lambda <- 1 #mayoriza la función lambdat
  TT <- rexp(n,lambda) #genera variables exponenciales para los tiempos.
  s <- cumsum(TT) #acumula los tiempos en el vector s
  u <- runif(n) #obten n uniformes
  ss <- s[u <= lambdat(s)/lambda] #obten los tiempos que cumplen la condición de aceptación
  Ns <- 1:length(ss) # Conteo
  plot(ss, Ns, type = "s", xlab = "epocas", ylab = "N(t)",
       main = "Simulación de un proceso Poisson no homogeneo",
       sub = expression(lambda(t) == paste("sin","(t)")))
  return(list(epocas = ss, cuenta= Ns))
}

x <- pphn(lambdat,100)

```

Simulacion de un proceso Poisson no homogeneo



```
x
$epocas
[1] 1.156444 1.447589 1.545649 1.552236 1.727585 2.229193 2.816492
[8] 3.953588 4.409725 4.761165 5.300725 5.304903 8.299511 11.958019
[15] 14.199565 14.827901 15.863703 17.521399 22.803352 23.532837 24.038860
[22] 24.385218 24.404631 24.552686 25.464197 26.289372 29.691469 30.174817
[29] 32.057273 32.252766 32.806239 33.006611 33.103138 33.168834 33.271402
[36] 35.121519 35.685809 36.374653 38.481711 40.229621 41.603202 42.301236
[43] 45.292080 47.421639 47.964861 51.129163 52.482674 54.439863 57.427575
[50] 57.873739 67.474235 67.965336 70.379400 70.593735 73.767571 76.787640
[57] 77.085360 79.379497 80.993811 81.132659 82.963705 85.615073 86.050630
[64] 87.219433 91.208226 92.519156 93.798390 96.362216 96.430616 99.163415

$cuanta
[1] 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25
[26] 26 27 28 29 30 31 32 33 34 35 36 37 38 39 40 41 42 43 44 45 46 47 48 49 50
[51] 51 52 53 54 55 56 57 58 59 60 61 62 63 64 65 66 67 68 69 70
```

□

4. Una máquina es sujeta a shocks que llegan de dos fuentes independientes. Los shocks de la fuente 1 llegan de acuerdo a un proceso Poisson con tasa de 3 por día y los de la fuente 2 a una tasa de 4 por día. ¿Cuáles son la media y varianza del número total de shocks que llegan de ambas fuentes en un turno de 8 hrs?
 - ¿Cuál es la probabilidad de que la máquina se encuentre sujeta a un total de exactamente dos shocks en una hora?

- Supongan que un shock de la fuente i puede causar que la máquina falle con probabilidad p_i , independiente de todo lo demás. Supongan que $p_1 = 0.011$ y $p_2 = 0.005$. La máquina descompuesta se reemplaza de manera inmediata. Sea $N(t)$ el número de reemplazos de la máquina sobre el intervalo $(0, t]$. ¿Es $\{N(t), t \geq 0\}$ un proceso Poisson, y si lo es, ¿cuál es el parámetro?

Solución.

- Para la primera parte de la pregunta, sólo hay que notar que el total de shocks N_t corresponde a una superposición de procesos Poisson $N_t^{(1)}$ y $N_t^{(2)}$, $N_t = N_t^{(1)} + N_t^{(2)}$, por lo que el parámetro de la superposición es $\lambda_1 + \lambda_2 = 3 + 4 = 7$. en un periodo de 8 horas, se tiene que $E(N_t) = 7 \times 8/24 = 56/24$ y la varianza en el proceso Poisson es la misma que la media, $\text{Var}(N_t) = 56/24$.
- La probabilidad de dos shocks en una hora se obtiene considerando que $N_1 \sim \text{Poi}(7)$. Por lo tanto es $P(N_1 = 2)$

```
dpois(2, lambda= 7)
```

```
[1] 0.02234111
```

- Este problema puede ser tratado como un adelgazamiento de cada uno de los procesos $N_t^{(1)}$ y $N_t^{(2)}$ y luego a una superposición de los procesos ya adelgazados. Cada proceso $N^{(i)}$ se puede escribir como la suma de los shocks que descomponen la máquina y los que no lo descomponen. Sea $R^{(i)}$ la parte del proceso que descompone la máquina. Estos procesos son procesos adelgazados que tienen parámetro $p_i * \lambda_i$. EL proceso $R_t^{(1)} + R_t^{(2)}$ que corresponde al número de reemplazo de máquinas es un proceso Poisson con parámetro $p_1 * \lambda_1 + p_2 * \lambda_2 = 0.011 \times 3 + 0.005 \times 4 = 0.053$.

□

5. Las ocurrencias de huracanes que tocan tierra durante el fenómeno meteorológico “el Niño” se modelan como un proceso Poisson (ver Bove et al (1998)). Los autores aseguran que “Durante un año de ‘El Niño’, la probabilidad de dos o más huracanes haciendo contacto con tierra en los estados Unidos es 0.28”. Encontrar la tasa del proceso Poisson.


Solución.

Este problema dice que un proceso Poisson con parámetro λ cumple la siguiente condición: $P(N_2 \geq 2) = 0.28$. Entonces tenemos que encontrar λ .

$$\begin{aligned}
 P(N_2 \geq 2) &= 1 - \sum_{i=0}^1 \frac{e^{-\lambda} \lambda^i}{i!} \\
 &= 1 - e^{-\lambda}(1 + \lambda) \\
 &= 0.28
 \end{aligned}$$

Tenemos que resolver la ecuación: $e^{-\lambda}(1 + \lambda) = 0.78$

```
g <- function(x) exp(-x) * (1+x) - 0.72
curve(g, 0, 1.5)
abline(h=0)
```



```
a <- uniroot(g, interval=c(1,1.5))
a

$root
[1] 1.042851

$f.root
[1] -3.173615e-07

$iter
[1] 3

$init.it
[1] NA

$estim.prec
[1] 6.103516e-05
```

Entonces $\lambda = 1.0428507824926$

□

6. Comenzando a mediodía, los comensales llegan a un restaurante de acuerdo a un proceso Poisson a una tasa de 5 clientes por minuto. El tiempo que cada cliente pasa comiendo en el restaurante tiene una distribución exponencial con media de 40 minutos, independiente de otros clientes e independiente de los tiempos de arribo. Encuentra la distribución así como la media y varianza, del número de comensales en el restaurante a las 2:00pm. Simular el restaurante para verificar los resultados obtenidos.

Solución.

Sea X_t el número de clientes que llegan en el tiempo t . De acuerdo al problema, X_t sigue un proceso Poisson con media 5 cada hora. Sea t_i el tiempo de servicio del cliente i . De acuerdo al problema, $t_i \sim \exp(1/40)$

Nos piden determinar el número de clientes al tiempo t . Sea N_t este número. La distribución de N_t se puede obtener condicional al número de clientes que han llegado al restaurante y los que ya están ahí. Entonces:

$$P(N_t = k) = \sum_{n=k}^{\infty} P(N_t = k | X_t = n) P(X_t = n) = \sum_{n=k}^{\infty} P(N_t = k | X_t = n) \frac{e^{-\lambda t} (\lambda t)^n}{n!}$$

Si los n clientes en el restaurante llegaron en s_1, \dots, s_n , entonces los clientes dejan el restaurante en los tiempos $s_i + t_i$. Ahora, noten que hay k clientes en el restaurante si y sólo si hay k índices tales que $s_i + t_i > t$, por lo que, recordando que los tiempos de arribo se distribuyen como las estadísticas de orden, se tiene

$$\begin{aligned} P(N_t = k | X_t = n) &= P(k \text{ de los } n \text{ valores } s_i + t_i > t | X_t = n) \\ &= P(k \text{ de los } n \text{ valores } u_{(i)} + t_i > t | X_t = n) \\ &= P(k \text{ de los } n \text{ valores } u_i + t_i > t | X_t = n) \\ &= \binom{n}{k} p^k (1-p)^{n-k} \end{aligned}$$

La probabilidad de éxito en este caso es $P(U_1 + t_1 > t) = \frac{1}{t} \int_0^t P(t_1 > t - x) dx = \frac{1}{t} \int_0^t (1 - F(t - x)) dx = \frac{1}{t} \int_0^t (1 - F(x)) dx$.

$$\begin{aligned}
P(N_t = k) &= \sum_{n=k}^{\infty} \binom{n}{k} p^k (1-p)^{n-k} \frac{e^{-\lambda t} (\lambda t)^n}{n!} \\
&= \frac{p^k (\lambda t)^k}{k!} \sum_{n=k}^{\infty} (1-p)^{n-k} \frac{e^{-\lambda t} (\lambda t)^{n-k}}{(n-k)!} \\
&= \frac{p^k (\lambda t)^k}{k!} e^{\lambda(1-p)t} e^{-\lambda t} \\
&= \frac{p^k (\lambda t)^k}{k!} e^{-\lambda p t}
\end{aligned}$$

Así que el número de restaurantes es un proceso adelgazado (podemos separarlo en los clientes que siguen y en los clientes que ya se fueron) y la probabilidad depende de la distribución de los tiempos de arribo. Para nuestro problema, $t = 120$ (dos horas después del mediodía y con unidad de tiempo el minuto) $p_t = \frac{40(1-e^{120/40})}{120} = 0.3167$, y por lo tanto el número esperado de clientes en el cliente a las 2 de la tarde es $5 \times p \times 120 = 190.0426$


Simulando el sistema:

```
# Simula un proceso Poisson

pp <- function(t,lambda){
  N <- rpois(1,lambda*t)
  u <- runif(N,0,t)
  return(list(tiempos=sort(u),conteo = 1:N, total = N))
}
a <- pp(120,5) # proceso Poisson(5) evluado n t = 120
plot(a$tiempos,a$conteo,type = "s")

# Sobre los tiempos, sumamos los tiempos que corresponden al tiempo que tardan en comer
# cada uno de los clientes
tc <- rexp(a$total,rate = 1/40)

rug(a$tiempos)
nt <- a$tiempos + tc
rug(nt[nt<=120],col = "red")
# Conteo de los que se van antes de las 2 hrs.
lines(sort(nt[nt<120]),1:length(nt[nt<120]),col = "red", type ="s")
```



```
# Simula para calcular la media de los que no se han ido a las 2 hrs
```

```
res <- NULL
for(i in 1:10000){
  a <- pp(120,5)
  nt <- a$tiempos + rexp(a$total,rate = 1/40)
  res[i] <- length(nt[nt>120])
}
```

```
mean(res)
```

```
[1] 190.3767
```

```
sd(res)
```

```
[1] 13.82229
```

□

7. Sea X_t que satisface la ecuación diferencial estocástica $dX_t = -\frac{1}{3}dt + \frac{1}{2}dZ_t$, donde $X_0 = 0$ y Z_t es un proceso de Wiener estándar. Definan $S_t = e^{X_t}$ así que $S_0 = 1$.
- Encontrar la ecuación diferencial estocástica que sigue S_t
 - Simular 10 trayectorias de S_t para $t = 1, \dots, 30$. Llamen a esas trayectorias S_t^i , $i = 1, \dots, 10$ y gráfiquenlas en la misma gráfica.
 - ¿Qué se puede concluir sobre S_t para t grande?

- Con $n = 10$. evaluar $\bar{S}_{30} = \frac{1}{n} \sum_{i=1}^n S_{30}^i$.
- Simular 100 trayectorias independientes y evaluar \bar{S}_{100} con la fórmula dada arriba con $n = 100$. ¿Qué se puede concluir sobre \bar{S}_{1000} cuando $n \rightarrow \infty$?


Solución.

- Aplicando la fórmula de Ito, que hicimos en clase, a $G(X, t) = e^{X_t}$, obtenemos que $dS_t = S_t dt + S_t dZ_t$
- Para simular las trayectorias:

```
BGeo <- function(n, TT, a, b, S0 = 1){
  # Función para generar un proceso Browniano Geométrico
  # n es el número de puntos de partición del intervalo [0,TT]
  # a es el drift y b la volatilidad

  dt <- TT/n #incremento de los intervalos para cubrir [0,TT]
  S <- S0 #valor inicial
  for(i in 2:(n+1)){
    S <- append(S, S[i-1]*exp((a-b^2/2)*dt + b*sqrt(dt)*rnorm(1)))
  }
  return(S)
}

plot(BGeo(n = 30, TT = 1, a = -0.3, b = 0.5, S0 = 1), type = "l",
      ylim = c(0,2), xlab = "tiempo", ylab = expression(S[t]))
abline(h = 1)
for(i in 1:10) lines(BGeo(30,1,-0.3,0.5,1))
```



- Podemos ver que la varianza crece cuando t crece como ya sabemos, pero la media parece tender a ser negativa.

```

S30 <- NULL
for(i in 1:10) S30[i] <- BGeo(30,1,-0.3,0.5,1)[30]
S30

[1] 0.5557008 0.6357064 0.5186123 0.3473275 0.5402613 0.5262218 1.6966094
[8] 0.4293865 0.6659437 0.4962864

mean(S30)

[1] 0.6412056

sd(S30)

[1] 0.3818819

```

- Este es como el ejercicio de arriba pero con $n = 100$:

```

S100 <- NULL
for(i in 1:100) S100[i] <- BGeo(100,1,-0.3,0.5,1)[100]
S100

[1] 0.3512556 0.8686633 0.7049163 0.3212150 1.6971439 0.5596593 0.6422189
[8] 0.4282768 1.7164081 0.7671254 0.6137362 0.2190055 0.9951213 0.8871927
[15] 1.9903307 0.4131432 0.9338997 0.3826419 0.4786844 0.6100982 0.6155368
[22] 0.8543113 0.5460138 0.6055372 0.8016313 0.9110656 0.8308149 0.3201241
[29] 0.7926637 1.0749062 1.7716437 0.8792847 0.4451177 1.1642340 0.6037655
[36] 1.1904333 0.4320932 0.4637130 0.4555791 0.5390291 1.3195169 0.7366638
[43] 0.4360978 1.0191959 0.9353211 0.8419030 0.8251485 0.6100356 0.3695865
[50] 1.4624807 0.3885751 1.0022101 1.4955577 0.2972225 0.6932528 0.4998177
[57] 0.3434639 0.2846758 1.0397888 0.8600553 0.7152472 1.0482260 1.1346993
[64] 0.6905379 0.2786404 0.7119424 0.8884609 0.6209028 0.8986302 0.4303360
[71] 1.2412902 0.9868548 1.2476295 0.4411096 1.2329850 1.1875648 0.5701531
[78] 0.3927023 0.6974068 0.3669915 2.2625719 0.7486518 1.0622894 0.9549669
[85] 0.3905040 0.3748865 1.4023212 1.5182162 0.3404229 0.7250680 0.4327181
[92] 0.6205835 1.4254467 0.4114172 0.4232662 0.6877344 0.4098998 0.7464361
[99] 1.2900240 0.3551852

mean(S100)

[1] 0.7870372

sd(S100)

[1] 0.411077


```

Para el punto 1000:

```

S1000 <- NULL
for(i in 1:10000) S1000[i] <- BGeo(100,1,-0.3,0.5,1)[100]
hist(log(S1000),breaks = 100)

```



```
summary(log(S1000))
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
-2.29130	-0.74638	-0.41794	-0.41880	-0.08344	1.70516

Como se espera, S_{1000} tiene distribución lognormal.

□


8. Considerar el precio de una acción que sigue el proceso de Wiener geométrico $\frac{dS_t}{S_t} = 0.10 dt + 0.30 dZ_t$ donde dZ_t es un proceso de Wiener.

- Usando $\Delta t = 1/12$ y $S_0 = 1$ simular 5,000 años del proceso $\log S_t$ y evaluar $\frac{1}{t} \log S_t$ como función de t . Noten que esta ecuación tiende a un límite p . ¿Cuál es el valor teórico de p ¿La simulación lo reproduce?
- Evaluar $\frac{1}{t} (\log S_t - pt)^2$ como una función de t . ¿tiende a un límite?


Solución.

- Para esta parte del ejercicio, tenemos:


```
plot(BGeo(n = 30, TT = 1, a = -0.3, b = 0.5, S0 = 1), type = "l", ylim = c(0, 2),
      xlab = "tiempo", ylab = expression(S[t]))
abline(h = 1)
for(i in 1:10) lines(BGeo(30, 1, -0.3, 0.5, 1))
```

```
S <- BGeo(n=5000*12, TT=5000, a=0.10, b=0.30, 1)
plot(log(S), type="l")
```



```
plot(0:60000, log(S)/0:60000, type = "l")
```




```
# valor de p
log(S[60000])/60000

[1] 0.004115358
```

El valor teórico de p es $\mu - \sigma^2/2 = 0.1 - 0.3^2/2 = 0.055$. Se reproduce el número. Esto es porque $\log S_t \sim \mathcal{N}(\mu - \sigma^2/2, \sigma^2 t)$.

- La varianza no converge, pues depende de t .

```
plot(0:60000, (log(S)-0.055*0:60000)^2/0:60000)
```



□