

EST-24107: Tarea 5

*Carlos Lezama, Marco Medina,
Emiliano Ramírez y Santiago Villarreal
Miércoles, 17 de noviembre de 2021*

Problema 1

Problema 2

Problema 3

Supongamos que queremos estimar $\int_0^1 e^{x^2} dx$.

Propongamos los siguientes dos estimadores:

1. $\hat{\theta}_1 = \frac{e^{u^2} (1 + e^{1-2u})}{2}$ y
2. $\hat{\theta}_2 = \frac{e^{u_1^2} + e^{u_2^2}}{2}$,

donde u, u_1 y u_2 son números aleatorios y $u_1 \perp u_2$.

Nótese que podemos reescribir

$$\begin{aligned}\hat{\theta}_1 &= \frac{e^{u^2} + e^{1-2u+u^2}}{2} \\ &= \frac{e^{u^2} + e^{(1-u)^2}}{2}\end{aligned}$$

Asimismo, podemos definir $h(x) = e^{x^2}$ tal que

$$\text{Cov}(h(u), h(1-u)) < 0$$

como consecuencia de que $h(\cdot)$ es monótona y $\hat{\theta}_1$ se trata del promedio de dos variables antitéticas.

Para $\hat{\theta}_2$, es fácil ver que por independencia

$$\text{Cov}(h(u_1), h(u_2)) = 0$$

y, por lo tanto, este estimador no alcanza reducción de varianza.

En consecuencia, el algoritmo definido por $\hat{\theta}_1$ es mejor que el descrito por $\hat{\theta}_2$.

De modo complementario, se puede observar una muestra numérica en la siguiente página.

```
set.seed(1234)

theta1 <- function(n) {
  u <- runif(n)
  theta <- (exp(u ^ 2) + exp((1 - u) ^ 2)) / 2
  return(c(estimate = mean(theta),
          sd = sd(theta)))
}

theta2 <- function(n) {
  u1 <- runif(n)
  u2 <- runif(n)
  theta <- (exp(u1 ^ 2) + exp((u2) ^ 2)) / 2
  return(c(estimate = mean(theta),
          sd = sd(theta)))
}

theta1(1000000)

## estimate      sd
## 1.4628581 0.1672392

theta2(1000000)

## estimate      sd
## 1.4628351 0.3356062
```

Problema 4

Problema 5

Problema 6

El número de reclamos que se harán en una aseguradora la próxima semana depende de un factor ambiental U . Si el valor de ese factor es $U = u$, entonces el número de reclamos tendrá distribución Poisson con media $\lambda = 15/(0.5 + u)$. Suponiendo que $U \sim \mathcal{U}(0, 1)$, definamos p como la probabilidad de que habrá al menos 20 reclamos la siguiente semana.

Para obtener una simulación cruda de p , podemos escribir

$$p = P(X > 20) = 1 - P(X \leq 20)$$

tal que

$$\begin{aligned} P(X \leq 20) &= \int_0^1 P(X \leq 20 | u) du \\ &= \int_0^1 \sum_{i=0}^{20} \frac{e^{-\lambda} \lambda^i}{i!} du \\ &= \sum_{i=0}^{20} \frac{1}{i!} \int_0^1 e^{-\lambda} \lambda^i du \\ &= \sum_{i=0}^{20} \frac{1}{i!} F(i). \end{aligned}$$

Entonces, podemos estimar cada integral $F(i)$, $\forall i = 0, 1, 2, \dots, 20$ como sigue:

```
f <- NULL

for (i in 0:20) {
  u <- runif(100000)
  y <- exp(-15 / (0.5 + u)) * (15 / (0.5 + u)) ^ i
  f[i + 1] <- mean(y)
}

p <- 1 - sum(f / factorial(0:20))

## [1] 0.2520797
```

Creamos la variable de control con la dependencia entre u y $X \mid u$ tal que

```

k <- 1000
n <- 100000

# Piloto
xu <- NULL
u <- runif(k)

for (i in 1:length(u)) {
  xu[i] <- rpois(1, 15 / (0.5 + u[i]))
}

a <- -lm(xu ~ u)$coeff[2]

# Simulación
u <- runif(n)
x <- NULL

for (i in 1:length(u)) {
  x[i] <- rpois(1, 15 / (0.5 + u[i]))
}

v <- x + a * (u - 0.5)
p <- mean(v > 20)

var(xu)

## [1] 42.44291

var(v)

## [1] 18.72857

p

## [1] 0.1956

```

Finalmente, para el caso de variables antitéticas:

```
f <- NULL

for (i in 0:20) {
  u <- runif(5000)
  u1 <- exp(-15 / (0.5 + u)) * (15 / (0.5 + u)) ^ i
  u2 <- exp(-15 / (0.5 + (1 - u))) * (15 / (0.5 + (1 - u))) ^ i
  f[i + 1] <- (mean(u1) + mean(u2)) / 2
}

p <- 1 - sum(f / factorial(0:20))

## [1] 0.2503782
```

Problema 7

Problema 8

Problema 9

Problema 10

Los siguientes datos corresponden a las horas adicionales de sueño de 10 pacientes tratados con un somnífero B comparado con un somnífero A:

```
sample <- c(1.2, 2.4, 1.3, 1.3, 0, 1, 1.8, 0.8, 4.6, 1.4)
```

A priori, sabemos que $\bar{y} \sim \mathcal{N}(\mu, \sigma^2/n)$ y $(n-1)\frac{s_y^2}{\sigma^2} \sim \chi_{(n-1)}^2$.

De esta forma, podemos generar muestras aleatorias de

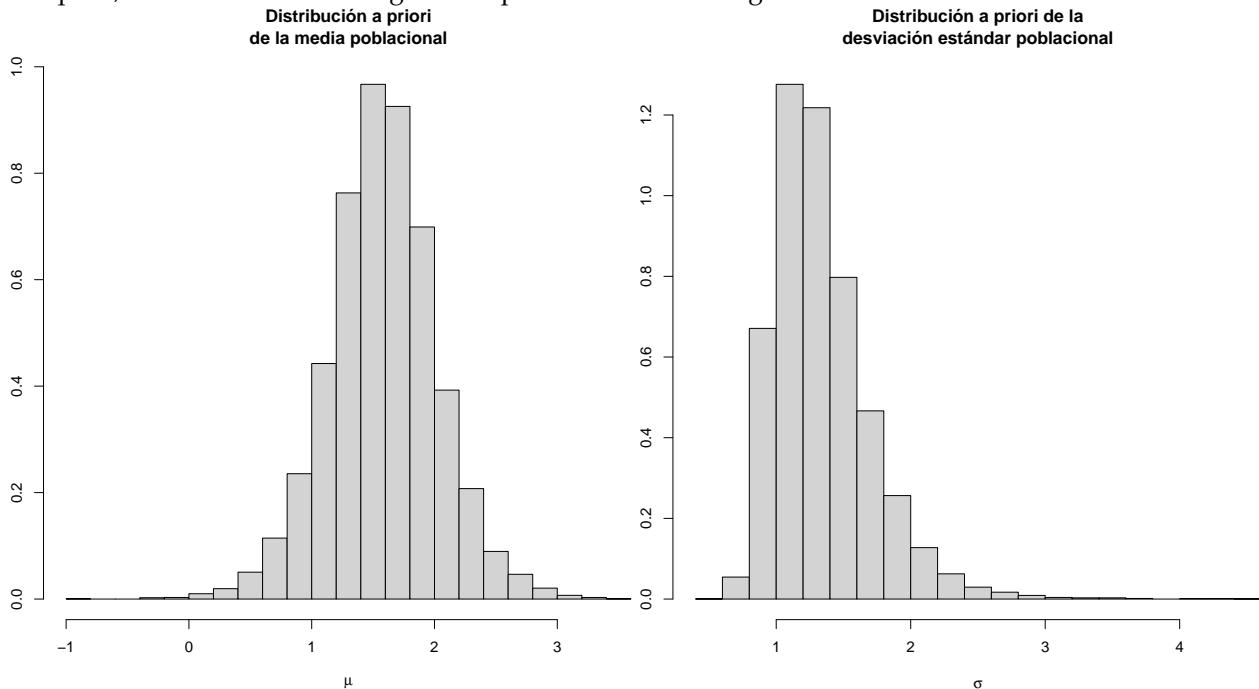
$$\sigma = \sqrt{(n-1)s_y^2/u_1}$$

tal que $u \sim \chi_{(n-1)}^2$. De forma análoga,

$$\mu = \bar{y} - \frac{u_2 \sigma}{\sqrt{n}}$$

donde $u_2 \sim \mathcal{N}(0, 1)$.

Así pues, las distribuciones marginales a priori se ven como sigue:



Sea $m = \log(\sigma^2)$ y $p(m) \propto c$ tal que c es constante, por el método de la transformación inversa, $p(\sigma^2) \propto c/\sigma^2$ y $p(\sigma) \propto c/\sigma$. Si asumimos μ y σ independientes a priori tal que $p(\mu, \sigma) = p(\mu)p(\sigma)$, tenemos que $p(\mu, \sigma) \propto c/\sigma$.

Ahora bien, definiremos la siguiente función para obtener las curvas de nivel de las distribuciones posteriores conjuntas, así como sus distribuciones marginales al asumir que $\text{sample} \sim f_Y(y | \mu, \sigma)$.

```

posterior <- function(f, a, b, c, d, rate.1, rate.2) {
  aa <- seq(a, b, rate.1)
  bb <- seq(c, d, rate.2)
  post <- outer(aa, bb, f)
  rownames(post) = aa
  colnames(post) = bb
  post <- as.data.frame(post) %>%
    rownames_to_column(var = 'row') %>%
    gather(col, value, -row) %>%
    mutate(row = as.numeric(row),
           col = as.numeric(col))
  post <- post[!is.infinite(rowSums(post)), ]
  post <- na.omit(post)
  p <- ggplot(post, aes(
    x = row,
    y = col,
    z = value,
    fill = value
  )) +
    geom_tile() +
    geom_contour(color = 'black', size = 0.5) +
    scale_fill_viridis(option = 'mako',
                       direction = -1) +
    theme_minimal() +
    labs(x = expression(mu),
         y = expression(sigma),
         fill = NULL)
  p.mu <- ggplot(post, aes(x = row,
                            y = value)) +
    geom_point(size = 0.1) +
    theme_minimal() +
    labs(x = expression(mu),
         y = NULL) +
    theme(axis.text.y = element_blank())
  p.sigma <- ggplot(post, aes(x = col,
                                y = value)) +
    geom_point(size = 0.1) +
    theme_minimal() +
    labs(x = expression(sigma),
         y = NULL) +
    theme(axis.text.y = element_blank())
  return(list(p, p.mu, p.sigma))
}

```

Distribución normal

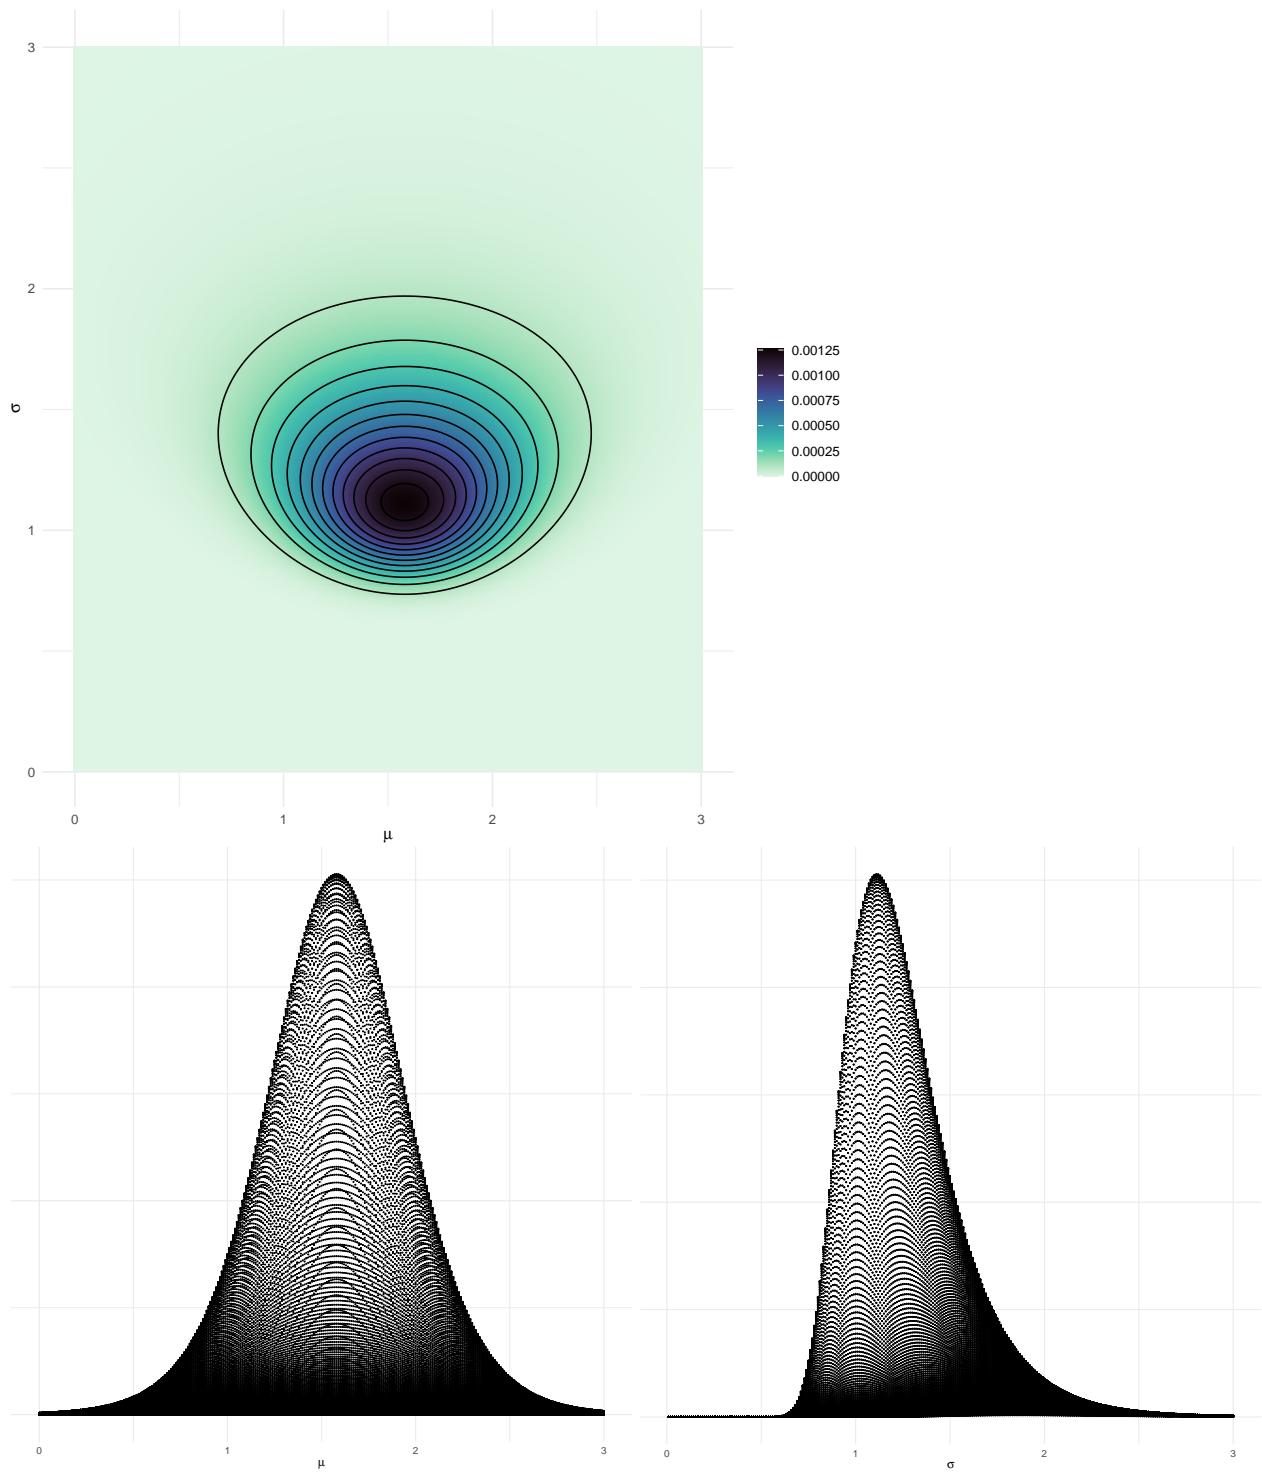
Sabemos $p(y | \mu, \sigma) \propto \ell(y | \mu, \sigma)$ donde $\ell(\cdot)$ es la función de verosimilitud correspondiente. Así pues,

$$\begin{aligned}
p(\mu, \sigma | y) &\propto p(y | \mu, \sigma) p(\mu, \sigma) \\
&\propto \ell(y | \mu, \sigma) p(\mu, \sigma) \\
&= \frac{c}{\sigma} (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2\right) \\
&= c(2\pi)^{-n/2} \sigma^{-n-1} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2\right) \\
&= \sigma^{-n-1} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2\right) \\
&= \sigma^{-n-1} \exp\left(-\frac{1}{2\sigma^2} \left(\sum_{i=1}^n (y_i - \bar{y})^2 + n(\bar{y} - \mu)^2 \right)\right) \\
&= \sigma^{-n-1} \exp\left(-\frac{1}{2\sigma^2} \left((n-1)s_y^2 + n(\bar{y} - \mu)^2 \right)\right)
\end{aligned}$$

De esta forma, podemos definir

```
bayes.norm <- function(a, b) {
  b ^ (-n - 1) *
  exp(-1 / (2 * b ^ 2) *
    (((n - 1) * (sample.sd ^ 2)) +
     (n * ((sample.mean - a) ^ 2
       ))))
}
```

Finalmente, podemos observar las siguientes curvas de nivel y distribuciones marginales $p(\mu | y)$ y $p(\sigma | y)$, respectivamente.



Adicionalmente, sabemos que

$$p(\mu \mid y) = \int_{\mathbb{R}_+} p(\mu, \sigma \mid y) d\sigma \implies \frac{\sqrt{n}(\mu - \bar{y})}{s_y} \Big| y \sim t_{(n-1)}$$

y

$$p(\sigma \mid y) = \int_{\mathbb{R}} p(\mu, \sigma \mid y) d\mu \implies \frac{(n-1)s_y^2}{\sigma^2} \Big| y \sim \chi^2_{(n-1)}$$

Distribución t

Sabemos que nuestra distribución t no centrada se define como sigue:

$$p(y | \hat{\mu}, \hat{\sigma}, v) = \frac{1}{\hat{\sigma}} k \left(1 + \frac{1}{v} \frac{(y - \hat{\mu})^2}{\hat{\sigma}^2} \right)^{-\frac{v+1}{2}}$$

donde

$$k = \frac{\Gamma\left(\frac{v+1}{2}\right)}{\sqrt{v\pi}\Gamma\left(\frac{v}{2}\right)},$$


$\hat{\mu}$ es la media desconocida de una normal, $\hat{\sigma} = s_y / \sqrt{n}$ y v es fija.

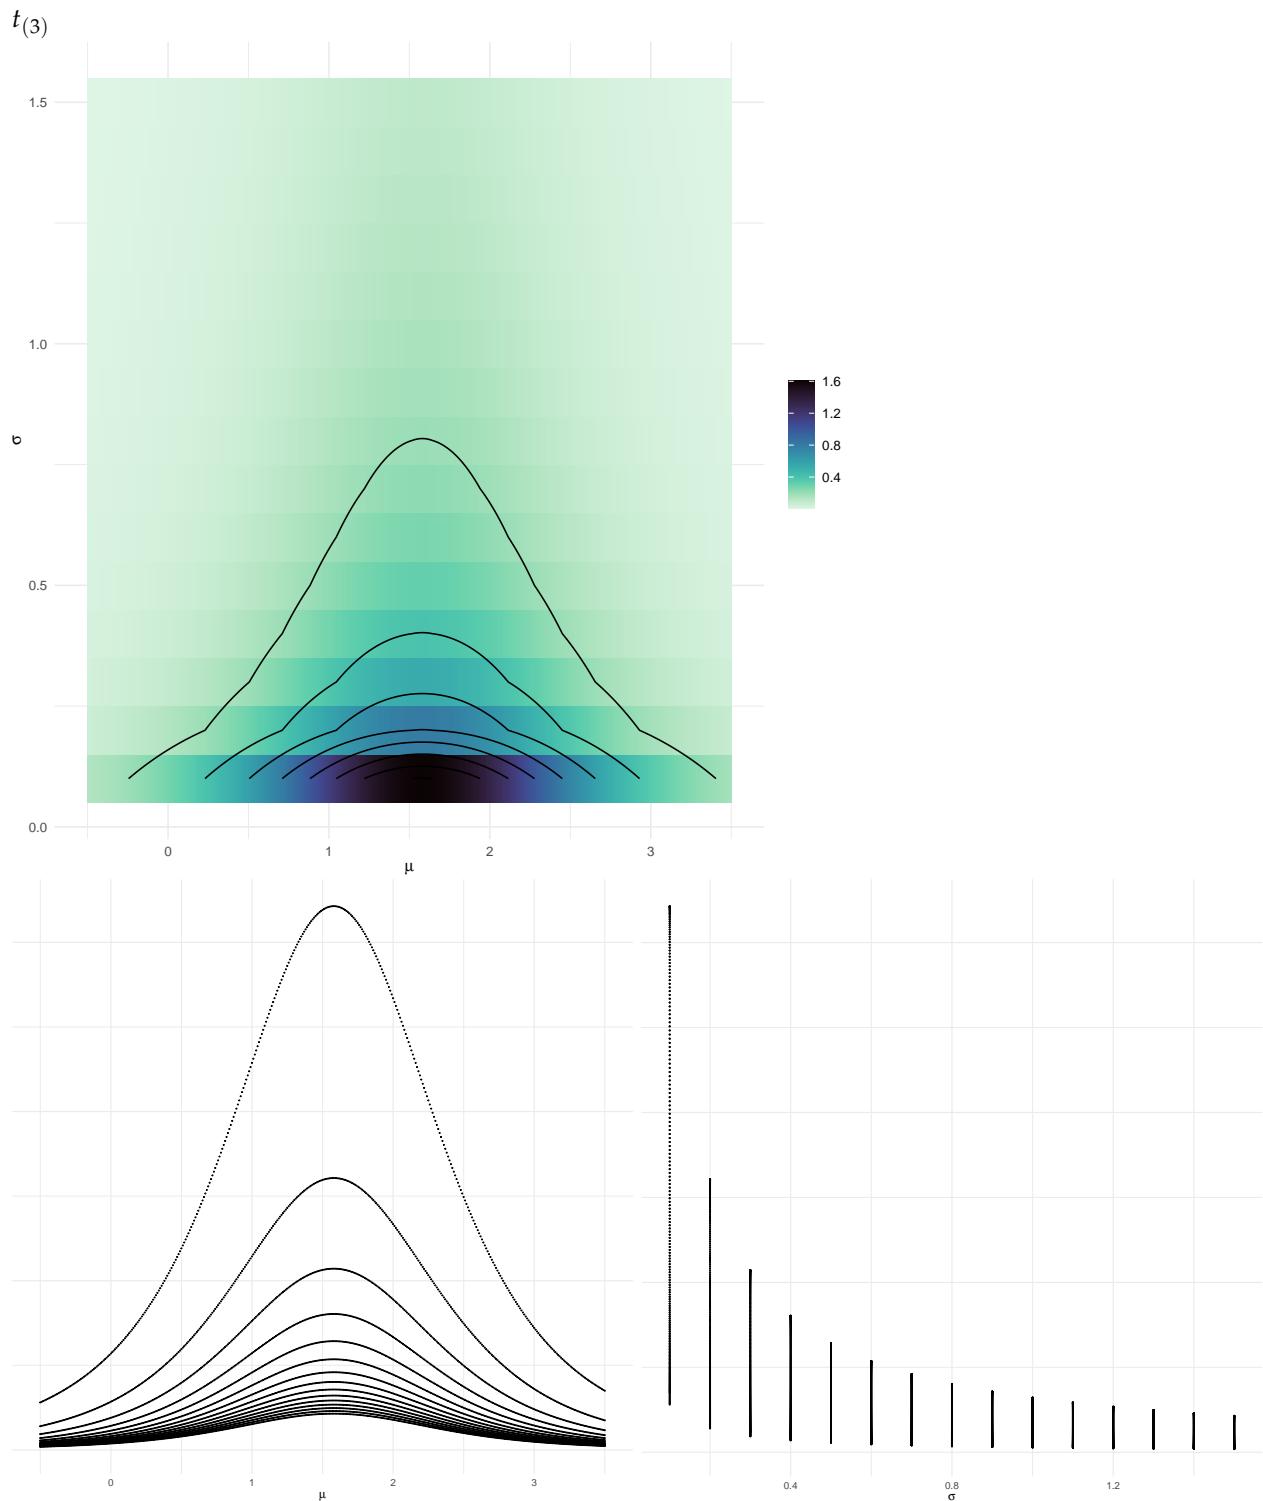
Por lo tanto,

$$\begin{aligned} p(\mu, \sigma | y) &\propto p(y | \mu, \sigma) p(\mu, \sigma) \\ &= k \frac{c}{\sigma} \frac{\sqrt{n}}{s_y} \left(1 + \frac{1}{v} \frac{n(y - \mu)^2}{s_y^2} \right)^{-\frac{v+1}{2}} \\ &= \frac{\sqrt{n}}{s_y \sigma} \left(1 + \frac{1}{v} \frac{n(y - \mu)^2}{s_y^2} \right)^{-\frac{v+1}{2}} \\ &= \frac{\sqrt{n}}{s_y \sigma} \left(1 + \frac{1}{v} \frac{\sum_{i=1}^n (y_i - \mu)^2}{s_y^2} \right)^{-\frac{v+1}{2}} \\ &= \frac{\sqrt{n}}{s_y \sigma} \left(1 + \frac{1}{v} \frac{(n-1)s_y^2 + n(\bar{y} - \mu)^2}{s_y^2} \right)^{-\frac{v+1}{2}} \end{aligned}$$

Finalmente, en la siguiente página, definimos las funciones para 1 y 3 grados de libertad, respectivamente.

```
bayes.t.1 <- function(a, b) {  
  (sqrt(n) / (b * sample.sd)) *  
  (1 + (((n - 1) * (sample.sd ^ 2)  
  ) +  
  (n * ((sample.mean - a) ^ 2  
  )))) /  
  (sample.sd ^ 2))) ^ (-1)  
}  
  
bayes.t.3 <- function(a, b) {  
  (sqrt(n) / (b * sample.sd)) *  
  (1 + (((((n - 1) * (sample.sd ^ 2)  
  ) +  
  ( (n * ((sample.mean - a) ^ 2)  
  )) /  
  (sample.sd ^ 2)) / 3))) ^ (-2)  
}
```





Bernoulli

Sabemos,

$$\begin{aligned}
 p(y | \mu) &\propto \ell(y | \mu) \\
 &= \prod_{i=1}^n \mu^{y_i} (1-\mu)^{1-y_i} \\
 &= \mu^{\sum_{i=1}^n y_i} (1-\mu)^{\sum_{i=1}^n (1-y_i)} \\
 &= \mu^{n\bar{y}} (1-\mu)^{n(1-\bar{y})}
 \end{aligned}$$

Además, $p(\mu) = c$. Por consiguiente,

$$\begin{aligned}
 p(\mu | y) &\propto p(y | \mu)p(\mu) \\
 &\propto c \cdot \mu^{n\bar{y}} (1-\mu)^{n(1-\bar{y})} \\
 &\propto \mu^{n\bar{y}} (1-\mu)^{n(1-\bar{y})}
 \end{aligned}$$

Finalmente, podemos observar su distribución posterior:

